

Курсовая работа по дисциплине «Классическое машинное обучение»

Тема: «Сравнение моделей машинного обучения для прогнозирования эффективности химических соединений»

Аналитический отчет

Выполнил:

студент учебной группы М25-525

Гаврилов Андрей(М2551187)

Актуальность курсовой работы

Процесс создания нового лекарственного препарата является сложным и многоэтапным. Необходимо определить химическую формулу, синтезировать соединение, провести первичные биологические испытания и организовать последующее тестирование. Эти этапы требуют значительных временных и ресурсных затрат, однако современные методы машинного обучения позволяют существенно ускорить процесс разработки.

Использование моделей машинного обучения дает возможность заранее оценивать эффективность химических соединений и отбирать наиболее перспективные варианты для дальнейшего изучения.

В задачах разработки лекарственных средств важна не только точность математических моделей, но и корректное взаимодействие между химиками и специалистами по машинному обучению. На практике это взаимодействие требует согласования терминологии, метрик и критериев качества, что делает задачу междисциплинарной и особенно значимой.

Постановка задачи

В рамках курсовой работы рассматриваются конфиденциальные данные о 1000 химических соединениях с параметрами эффективности против вируса гриппа.

Целевые показатели:

- IC50 – ингибирующая концентрация
- CC50 – цитотоксическая концентрация
- SI – индекс селективности

Показатель SI рассчитывается на основе параметров IC50 и CC50.

Остальные признаки датасета представляют собой числовые характеристики химических соединений.

Цель исследования

Построить и сравнить модели машинного обучения для прогнозирования эффективности химических соединений и определить подходы, наиболее полезные для предварительного отбора соединений в задачах разработки лекарственных препаратов.


1. Анализ и предобработка данных

Исходные данные:

- Размерность: 1001 запись, 214 столбцов
- Целевые переменные: IC50, CC50, SI
- Признаки: молекулярные дескрипторы (фрагментные счетчики, топологические и электронные свойства)

В ходе анализа было найдено незначительное кол-во пропусков - в 12 признаках по 3 пропуска в каждом, провели заполнение медианным значением, а также были удалены дубликаты.

Ниже представлены гистограмма с ядерной оценки плотности (KDE) для распределения и коробка с усами для выбросов.



Доля выбросов:

- IC50, mM: 14.24% выбросов
- CC50, mM: 3.61% выбросов
- SI: 12.38% выбросов

Было принято решение не удалять выбросы на начальном этапе, так как с большей вероятностью это негативно повлияет на обучение моделей. Также потеря примерно 15% данных при 1000 соединений снижает статистическую мощность и обобщающую способность модели, а также может исключить лучших кандидатов в лекарства.

Рассмотрим корреляцию подмножества наиболее значимых признаков.

Изучив определения признаков в датасете, стоит проанализировать ряд признаков представленных ниже.

Функциональные фрагменты:


- fr_amide - амидная группа - ключевой элемент для связывания с ферментами и GPCR.
- fr_Ar_N - атом азота в ароматическом кольце, который часто участвует в π -стэкинг и водородных связях.

Физико-химические свойства:

- MolWt - молекулярный вес.
- MolLogP - липофильность - влияет на проникновение через мембраны и связывание с гидрофобными карманами белка.
- TPSA - топологическая площадь полярной поверхности.
- qed (Quantitative Estimate of Drug-likeness) - количественная оценка "лекарственноподобности", коррелирует с безопасностью.

Топологические и электронные свойства:


- NumHDonors/NumHAcceptors - Доноры/акцепторы водородных связей, количество и расположение которых влияет на связывание.
- NumRotatableBonds - вращаемые связи, демонстрируют гибкость молекулы, из-за большого кол-ва связей теряется специфичность.
- NumAromaticRings - ароматические кольца, π -стэкинг с ароматическими аминокислотами.



По корреляционной матрицы можно выявить несколько важных закономерностей:

- Наиболее сильная положительная корреляция наблюдается между TPSA и NumHAcceptors (0.88), а также между MolWt и NumRotatableBonds (0.70). Это объясняется тем, что увеличение молекулярной массы закономерно ведет к росту числа акцепторов водородных связей и повышению гибкости молекулы.
- qed имеет умеренную отрицательную связь с MolWt (-0.68) и NumHAcceptors (-0.60). Это означает, что крупные молекулы с большим количеством акцепторов считаются менее лекарственноподобными.
- Наличие ароматических атомов азота (fr_Ar_N) умеренно коррелирует с NumAromaticRings (0.48) и NumHAcceptors (0.51), указывая на то, что ароматические атомы вносят вклад в общее число акцепторов.
- Стоит также обратить внимание на то, что слабая связь qed с fr_amide (0.04) и MolLogP (-0.19) говорит о том, что наличие амидной группы и липофильность в отдельности не определяют лекарственноподобность молекулы.
- NumHDonors практически не коррелирует с NumAromaticRings (0.06) и слабо с fr_Ar_N (-0.04), что свидетельствует о том, что доноры

водородных связей в основном сосредоточены в алифатических фрагментах.



Из графиков распределения выше можно сделать вывод о том, что признаки обладают различным спектром распределений и что важно разными масштабами. Это означает что в дальнейшем нужно будет масштабировать признаки перед использованием моделей.

В ходе первичной предобработки данных было выявлено, что датасет содержит незначительное количество пропусков, которые были заполнены медианными значениями. Дубли удалены. Таким образом, итоговый датасет для дальнейшего использования для моделей включает 969 записей и 213 признаков.

Анализ распределений целевых переменных – IC50, CC50 и индекса селективности SI – показал, что все они статистически значимо отличаются от нормального распределения. Это обосновывает необходимость их логарифмического преобразования перед построением моделей.

Доля выбросов в целевых признаках варьируется, однако было принято решение не удалять их, поскольку большие значения SI соответствуют

потенциально наиболее важным соединениям. Кроме того, удаление выбросов привело бы к потере статистической мощности и искажению распределений, тогда как используемые в дальнейшем алгоритмы устойчивы к выбросам.

Корреляционный анализ позволил выявить ожидаемые взаимосвязи между признаками. Наиболее сильная положительная корреляция наблюдается между топологической площадью полярной поверхности и числом акцепторов водородных связей, а также между молекулярной массой и числом вращаемых связей. Показатель лекарственноподобности QED отрицательно коррелирует с молекулярной массой и числом акцепторов, что подтверждает, что крупные молекулы с большим количеством акцепторов считаются менее лекарственноподобными.

Также установлено, что признаки имеют различные масштабы и типы распределений, что требует их масштабирования перед использованием в моделях машинного обучения.

2. Результаты моделирования

2.1. Регрессия IC50

Модель	MAE_train	MAE_test	RMSE_test	R^2_test
RandomForest	0.795916	1.080104	1.334494	0.517329
GradientBoosting	0.761460	1.089058	1.348086	0.507447
XGBoost	0.842383	1.105841	1.362694	0.496715
LGBMRegressor	0.595769	1.106040	1.402725	0.466711
Ridge	1.218355	1.275306	1.531045	0.364678
Lasso	1.334679	1.390099	1.666605	0.247194

В результате построения 6 моделей можно сделать следующие выводы:

Наилучшие показатели демонстрирует Random Forest, который достигает самой низкой ошибки на тестовой выборке ($RMSE = 1.334$, $MAE = 1.080$) и самого высокого коэффициента детерминации (0.517). Это означает, что модель объясняет примерно 51.7% дисперсии целевой переменной, а средняя ошибка предсказания составляет около 1.08 единиц IC50.

Gradient Boosting показывает близкие результаты ($R^2 = 0.507$, $RMSE = 1.348$), что характерно для древовидных ансамблей - они хорошо справляются с нелинейными зависимостями и взаимодействиями признаков, не требуя масштабирования данных.

XGBoost и LightGBM показали более высокую ошибку обобщения, хотя во многих задачах градиентный бустинг на деревьях часто превосходит случайный лес. Это может быть связано с переобучением LightGBM, так как она имеет наилучший MAE на обучении, но наибольший разрыв с тестом. Возможна неоптимальная настройка гиперпараметров, ведь для XGBoost и LGBM требуется более тщательный подбор, тогда как Random Forest менее чувствителен к параметрам. Дополнительно на качество мог повлиять малый размер выборки и сохранение "выбросов".

Линейные модели ожидаемо показывают худшие результаты. Это говорит о том, что зависимость IC50 от дескрипторов является нелинейной, и линейные аппроксимации недостаточно хорошо описывают данные.

Рекомендации

Для практического использования стоит выбрать Random Forest как наиболее сбалансированную модель с наилучшим R^2 и минимальной ошибкой на тесте. Для дальнейшего улучшения можно провести более глубокий подбор гиперпараметров для XGBoost/LGBM, добавить дополнительные признаки или рассмотреть нелинейные методы.

2.2. Регрессия CC50

Модель	MAE_train	MAE_test	RMSE_test	R^2_test
LGBMRegressor	0.511791	0.866899	1.236444	0.349214
Ridge	0.921574	0.938380	1.249546	0.335349
XGBoost	0.598558	0.909793	1.255976	0.328491
GradientBoosting	0.444545	0.857947	1.265509	0.318259
Lasso	1.060954	1.053567	1.309285	0.270278
RandomForest	0.157056	0.864429	1.316023	0.262748

В результате построения 6 моделей можно сделать следующие выводы:

Среди шести рассмотренных моделей регрессии лучший результат по основным метрикам показал LGBMRegressor, достигнув наибольшего $R^2 = 0.349$ и наименьшего $RMSE = 1.236$ на тестовой выборке. Ridge занял второе место с минимальным разрывом между MAE на обучении и тесте, что свидетельствует о хорошей обобщающей способности. XGBoost и градиентный бустинг продемонстрировали близкие результаты, тогда как Lasso и случайный лес оказались наихудшими.


Наиболее интересное наблюдение – это то, что случайный лес показывает отличные метрики на обучении, но сильное падение на тесте, что является классическим примером сильнейшего переобучения. С уверенностью можно сказать, что это связано с избыточной глубиной деревьев, и, возможно, недостаточным количеством объектов в выборке. В то время как LGBMRegressor и градиентный бустинг демонстрируют более сбалансированное поведение, а линейные модели – минимальный разрыв между метриками на тренировочной и тестовой выборках, что подтверждает устойчивость линейных моделей к переобучению на небольших данных.

Рекомендации:

В качестве финальной модели для предсказания CC50 рекомендуется LGBMRegressor как наилучшая модель по R^2 и RMSE. Для улучшения качества можно провести более глубокую настройку гиперпараметров, например, num_leaves, min_child_samples, learning_rate, а также применить раннюю остановку для борьбы с переобучением. Для случайного леса необходимо ужесточить регуляризацию - уменьшить max_depth, увеличить min_samples_split и min_samples_leaf. Учитывая, что максимальный R^2 не превышает 0.35, целесообразно рассмотреть добавление новых признаков или перейти к использованию более сложных моделей - ансамблей, способным лучше учитывать особенности данных.

2.3. Регрессия SI

Модель	MAE_train	MAE_test	RMSE_test	R^2_{test}
XGBoost	0.747363	0.977463	1.307245	0.243659
RandomForest	0.559398	0.947351	1.310348	0.240064
GradientBoosting	0.648093	0.970360	1.328275	0.219129
LGBMRegressor	0.486979	0.958781	1.345934	0.198228
Ridge	0.929176	1.032740	1.351497	0.191586
Lasso	0.918949	1.046976	1.361603	0.179451



В результате построения 6 моделей можно сделать следующие выводы:

Среди шести рассмотренных моделей лучшую обобщающую способность показал XGBoost, достигнув наибольшего $R^2 = 0.244$ и минимального RMSE на тестовой выборке. RandomForest продемонстрировал близкие результаты и минимальную абсолютную ошибку $MAE = 0.947$. Однако у обеих древовидных моделей наблюдается заметное переобучение, так как разрыв MAE между train и test составляет примерно 0.35-0.4. Линейные модели показали худшие результаты, что подтверждает нелинейный характер зависимости целевой переменной SI от молекулярных дескрипторов.

Анализ важности признаков показал, что наибольший вклад в предсказание вносят фрагментные счетчики - fr_Imine, fr_Al_COO, fr_Ndealkylation1, и топологические индексы - BalabanJ, AvgIpc, что подчеркивает значимость химической структуры. При этом общий R^2 довольно низкий, то есть модель объясняет лишь около 24% дисперсии целевой переменной - этого недостаточно для надежного промышленного применения.

Рекомендации:

Для улучшения качества рекомендуется стоит рассмотреть применение ранней остановки в XGBoost и LightGBM для борьбы с переобучением, а также провести отбор топ-20 признаков для повышения стабильности линейных моделей. В перспективе стоит рассмотреть использование стекинга нескольких моделей, например XGBoost и RandomForest или перейти к использованию ансамблей, способным лучше учитывать топологию молекул. В текущем виде лучшей моделью для предсказания SI является XGBoost с последующей калибровкой гиперпараметров под конкретную задачу.

2.4. Классификация IC50 > медианы

Модель	Accuracy	F1	ROC-AUC
RandomForest	0.747	0.754	0.828
GradientBoosting	0.737	0.741	0.814
XGBoost	0.722	0.730	0.814
LogReg	0.716	0.721	0.772

Среди четырех рассмотренных моделей классификации лучший результат показал RandomForest, достигнув ROC-AUC = 0.828. GradientBoosting занял второе место незначительно уступив случайному лесу по всем метрикам. XGBoost показал результаты, близкие к градиентному бустингу, в то время как логистическая регрессия оказалась наихудшей, что объясняется нелинейным характером зависимости между молекулярными дескрипторами и бинарной активностью IC50.

Все модели демонстрируют хорошую разделяющую способность - значения ROC-AUC в диапазоне 0.77-0.83 указывают на хорошее качество бинарной классификации. Стоит обратить внимание на то, что GradientBoosting и XGBoost показывают практически идентичные значения ROC-AUC, однако XGBoost уступает по точности, что может быть связано с различными стратегиями регуляризации.

Рекомендации:

В качестве финальной модели для предсказания $IC_{50} >$ медианы рекомендуется использовать RandomForest как лучший по всем трем метрикам. Для повышения качества можно дополнительно настроить гиперпараметры через более широкую сетку поиска, например, увеличить количество деревьев до 500. Также стоит рассмотреть ансамблирование топ-3 моделей через голосование для потенциального улучшения ROC-AUC. При необходимости интерпретируемости можно использовать логистическую регрессию с нелинейными признаками.

2.5. Классификация $CC_{50} >$ медианы

Модель	Accuracy	F1	ROC-AUC
GradientBoosting	0.722	0.727	0.816
RandomForest	0.716	0.721	0.812
XGBoost	0.722	0.733	0.799
LogReg	0.711	0.720	0.782

По результатам классификации целевой переменной $CC_{50} >$ медианы лучшей моделью оказался градиентный бустинг, показавший наибольший $ROC-AUC = 0.816$ и точность в 0.722. В данной задаче случайный лес уступил по всем метрикам и занял второе место с $ROC-AUC = 0.812$. XGBoost продемонстрировал самую высокую F1-меру = 0.733 при чуть более низком ROC-AUC, тогда как логистическая регрессия вновь оказалась худшей, что подтверждает нелинейность зависимости между молекулярными дескрипторами и токсичностью CC_{50} .

Стоит отметить, что по сравнению с задачей $IC_{50} >$ медианы, здесь наблюдается небольшое снижение качества предсказания. Это может указывать на то, что токсичность CC_{50} является более сложной или зашумленной целевой переменной, чем активность IC_{50} . При этом

градиентный бустинг и случайный лес остаются лидерами, а XGBoost показывает менее стабильные результаты.

Рекомендации:

В качестве финальной модели для предсказания $CC_{50} >$ медианы рекомендуется градиентный бустинг как лидер по ROC-AUC и точности. Для улучшения качества можно провести более тщательный подбор гиперпараметров, в частности `learning_rate` и `max_depth`, или добавить признаки, связанные с токсикологическими свойствами молекул, например, наличие специфических функциональных групп. Учитывая близость результатов топ-3 моделей, целесообразно применить голосование, с весами, пропорциональными ROC-AUC для повышения устойчивости предсказаний.

2.6. Классификация $SI >$ медианы

Модель	Accuracy	F1	ROC-AUC
RandomForest	0.670	0.619	0.721
GradientBoosting	0.639	0.615	0.690
XGBoost	0.629	0.591	0.684
LogReg	0.608	0.596	0.652

Среди четырех рассмотренных моделей классификации лучший результат показал случайный лес, достигнув $ROC-AUC = 0.721$, точность = 0.670 и $F1 = 0.619$. Градиентный бустинг уступает в этой задаче и занимает второе место сильно уступив случайному лесу по точности. XGBoost и LogReg показали значительно более низкие результаты: ROC-AUC составил 0.684 и 0.652 соответственно. При этом логистическая регрессия все также показывает худший результат, что лишний раз подтверждает нелинейный характер зависимости между молекулярными дескрипторами и селективностью SI.

Важно отметить, что все модели демонстрируют существенно более низкое качество по сравнению с задачами IC_{50} (ROC-AUC до 0.828) и CC_{50} (ROC-

AUC до 0.816). Максимальный ROC-AUC = 0.721 у случайного леса является лишь удовлетворительным показателем и указывает на то, что предсказать превышение медианы по SI значительно сложнее. Особенно низкие значения F1-меры (0.59–0.62) свидетельствуют о проблемах недостаточной информативности используемых признаков именно для показателя селективности.

Рекомендации:

В качестве финальной модели для предсказания $SI >$ медианы рекомендую использовать случайный лес, как наилучшую модель по всем трем метрикам. Поскольку данные сбалансированы, основное внимание следует уделить расширению набора данных или применению более сложных моделей, таких как ансамблевые методы или метод голосования.

Учитывая низкое качество всех моделей, возможно, бинаризация данного признака по медиане плохо отражает природу SI, и стоит рассмотреть иные классификации, например $IS > 8$, как в следующей задаче.

2.7. Классификация $SI > 8$

Модель	Accuracy	F1	ROC-AUC
XGBoost	0.861	0.819	0.939
GradientBoosting	0.830	0.784	0.926
LogReg	0.825	0.746	0.919
RandomForest	0.830	0.723	0.912

По результатам классификации целевой переменной $SI > 8$ лучшей моделью стал XGBoost, показавший отличные результаты: ROC-AUC = 0.939, точность = 0.861 и F1 = 0.819. Градиентный бустинг и случайный лес продемонстрировали приблизительно одинаковую точность, однако градиентный бустинг существенно превзошел случайный лес по F1-мере, что указывает на лучший баланс между полнотой и точностью. Логистическая

регрессия заняла предпоследнее место, и ее F1-мера оказалась выше, чем у RandomForest, несмотря на более низкую точность.

Ключевое отличие данной задачи от классификации $SI > \text{медианы}$ - улучшение качества всех моделей. Если при бинаризации по медиане лучший ROC-AUC составлял лишь 0.721, то при пороге > 8 показатель достигает 0.939, что является отличным результатом. Это объясняется тем, что порог > 8 выделяет молекулы с действительно высокой селективностью, которые сильнее отличаются по своим свойствам от остальных, тогда как медиана размывает границы между классами. XGBoost уверенно лидирует во всех метриках, подтверждая свою эффективность на сложных нелинейных зависимостях.

Рекомендации:

В качестве финальной модели для предсказания $SI > 8$ рекомендуется XGBoost с лучшими показателями. Для дальнейшего улучшения можно провести более тонкую настройку гиперпараметров, например, оптимизировать параметры под существующий дисбаланс классов или добавить регуляризацию.

3. Заключение

В ходе выполнения курсовой работы проведено сравнение моделей классического машинного обучения для прогнозирования эффективности химических соединений. Анализ и предобработка данных выявили незначительное количество пропусков и дубликатов, а также существенную долю выбросов в целевых переменных, от которых было решено не избавляться для сохранения потенциально активных соединений. Корреляционный анализ подтвердил нелинейный характер зависимостей между молекулярными дескрипторами и целевыми показателями, что в дальнейшем предопределило превосходство ансамблевых моделей над линейными. Наилучшие результаты регрессии показали случайный лес для

IC50 и LGBMRegressor для CC50, однако прогнозирование индекса селективности SI осталось сложной задачей, на которой не удалось достигнуть таких же результатов как в других задачах.

Бинарная классификация продемонстрировала значительно более высокое качество по сравнению с регрессией. Для задач классификации активности и токсичности лучшие модели достигли ROC-AUC в диапазоне 0.81–0.83, что является хорошим показателем. Ключевым результатом работы стало обнаружение того, что бинаризация SI по жесткому порогу (>8) дает отличное качество прогнозирования с использованием XGBoost, тогда как бинаризация по медиане приводит лишь к удовлетворительным результатам. Это подтверждает, что выбор обоснованного предметной областью порога важнее простого статистического разделения.

Практическая значимость работы заключается в том, что разработанные модели могут использоваться для оценки химических соединений на этапе доклинических исследований, позволяя отбирать наиболее перспективные кандидаты и сокращая временные и ресурсные затраты. Наилучшей моделью для большинства задач признан XGBoost, показавший стабильно высокие результаты как в регрессии, так и в классификации. Для дальнейшего улучшения качества рекомендуется провести более глубокую настройку гиперпараметров, особенно для LightGBM и XGBoost с применением ранней остановки, а также рассмотреть возможность стекинга моделей или построения ансамблей.